Самовозбуждающиеся процессы вместо ручных оконных признаков

Формулировка исследовательской идеи для задачи автоматизации построения признаков в рекомендательных системах

Октябрь 2026

Аннотация

Ручные признаки вида «число взаимодействий пользователя с сущностью за последние W дней» — основа градиентного бустинга в рекомендательных системах. Выбор окна W, типа связи и способа агрегации делает человек. Предлагается рассматривать историю взаимодействий как маркированный самовозбуждающийся (хоуксовский) точечный процесс с экспоненциальными ядрами. Тогда (i) достаточной статистикой истории является конечный набор экспоненциально затухающих счётчиков, обновляемых за $O(1)$ на событие; (ii) любой оконный счётчик приближается их линейной комбинацией; (iii) скорости затухания оцениваются методом максимального правдоподобия, а не задаются вручную; (iv) оценённые коэффициенты возбуждения автоматически отбирают полезные типы связей. Счётчики с оценёнными параметрами подаются в бустинг вместо (или в дополнение к) ручным оконным агрегатам. Документ содержит формальную постановку, математические утверждения с доказательствами, процедуру оценивания, диагностику и протокол эксперимента.

1. Постановка задачи

1.1. Данные

Имеется лог событий $\mathcal{E} = \{e = (u_e, i_e, t_e, m_e, o_e)\}$: пользователь $u_e \in U$, объект $i_e \in I$, момент $t_e \in \mathbb{R}_+$, марка (тип события) $m_e \in M$, флаг источника $o_e \in \{\text{org}, \text{rec}\}$ (органическое событие или событие из рекомендательной ленты). Для Yambda $M = \{\text{listen}^+, \text{listen}^-, \text{like}, \text{dislike}, \ldots\}$, где $\text{listen}^\pm$ — прослушивание с долей $\geq 50\%$ и $< 50\%$ соответственно.

Объектам приписаны атрибуты через отображения $a_r \colon I \to A_r$, $r \in R$. Для Yambda $R = \{\text{item}, \text{album}, \text{artist}\}$ с $a_{\text{item}} = \text{id}$; для KION R включает жанры, страны, актёров, режиссёров, студии. Множество R перечисляется автоматически из схемы данных — это единственное место, где возникают «типы связей», и оно не требует экспертного выбора.

1.2. Целевая переменная

Строка обучающей выборки — тройка (u, i, t) с меткой $y \in \{0, 1\}$. Основная постановка (Yambda): строки — прослушивания из рекомендательной ленты ($o_e = \text{rec}$), $y = \mathbf{1}\left[m_e = \text{listen}^+\right]$. Это задача «показ → дослушал» с естественными негативами (скипами), не требующая искусственной генерации кандидатов. Аналог для KION: $y = \mathbf{1}\left[\texttt{watched_pct} \geq 50\right]$ при условии начатого просмотра.

1.3. Ограничение point-in-time

Любой признак строки (u, i, t) есть функция только от

$$\mathcal{H}(u, t^-) = \{e \in \mathcal{E} : u_e = u,\ t_e < t\},$$

а также от статистик, вычисленных по событиям до момента разбиения. Само целевое событие и события после t в признаки не входят. Для данных с дневной гран ярностью (KION) неравенство $t_e < t$ понимается как «строго предыдущий день».

2. Ручные признаки как оконные агрегаты

Подавляющее большинство ручных признаков описывается четвёркой (связь, марка, окно, статистика). Базовый объект — *оконный счётчик*

$$C^W_{r,m}(u, i, t) = \sum_{e \in \mathcal{H}(u,t^-)} \mathbf{1}\left[m_e = m\right]\, \mathbf{1}\left[a_r(i_e) = a_r(i)\right]\, \mathbf{1}\left[t - t_e \le W\right]. \tag{1}$$

Примеры: $r = \text{item}$ — «сколько раз слушал этот трек за W дней» (прямая связь); $r = \text{artist}$ — «сколько раз слушал этого артиста» (косвенная связь). Отношения $C^W_{r,\text{like}}/C^W_{r,\text{listen}}$ дают конверсии; величина $t - \max\{t_e\}$ — время с последнего события.

Ручной процесс — перебор по сетке $W \in \{1\text{ч}, 1\text{д}, 7\text{д}, 30\text{д}, \infty\}$, по $r \in R$, по $m \in M$. Вопросы из постановки задания — «почему 7 дней?», «какие связи?», «какие агрегации?» — суть вопросы о выборе точек этой сетки. Цель: заменить сетку объектом, параметры которого оцениваются из данных.

3. Точечные процессы и марковское свойство

3.1. Условная интенсивность

Пусть $N(t)$ — считающий процесс событий, $\mathcal{F}_t$ — порождённая историей фильтрация. Условная интенсивность

$$\lambda(t) = \lim_{h \downarrow 0} \frac{1}{h}\, \mathbb{P}\big(N(t+h) - N(t) > 0 \mid \mathcal{F}_{t^-}\big)$$

полностью определяет закон процесса. Процесс Хоукса задаётся интенсивностью

$$\lambda(t) = \mu + \sum_{t_j < t} \varphi(t - t_j), \qquad \varphi \ge 0, \quad \int_0^\infty \varphi(\tau)\, \mathrm{d}\tau = \alpha < 1, \tag{2}$$

где $\mu > 0$ — базовая (экзогенная) интенсивность, φ — ядро возбуждения, α — коэффициент ветвления (среднее число «потомков» одного события). Условие $\alpha < 1$ эквивалентно существованию стационарного режима.

3.2. Экспоненциальное ядро и затухающие счётчики

Определение 1 (затухающий счётчик)**.** Для $\beta > 0$ положим

$$S_\beta(t) = \sum_{t_j < t} e^{-\beta(t - t_j)}. \tag{3}$$

При $\varphi(\tau) = \alpha\beta e^{-\beta\tau}$ интенсивность (2) принимает вид $\lambda(t) = \mu + \alpha\beta\, S_\beta(t)$.

Утверждение 2 (марковское свойство)**.** *Пусть $\varphi(\tau) = \alpha\beta e^{-\beta\tau}$. Тогда:*

(i) между событиями S_β убывает детерминированно: $S_\beta(t+\Delta) = e^{-\beta\Delta} S_\beta(t)$ при отсутствии событий на $(t, t+\Delta]$;

(ii) в момент события t_j происходит скачок $S_\beta(t_j^+) = S_\beta(t_j^-) + 1$;

(iii) условное распределение будущего процесса при заданном $\mathcal{F}_t$ зависит от истории только через $S_\beta(t)$. В частности, процесс $(N(t), S_\beta(t))$ марковский, а $S_\beta(t)$ — достаточная статистика истории для предсказания.

Доказательство. (i), (ii) — прямая проверка по (3). (iii): закон процесса на (t, ∞) задаётся траекторией интенсивности, а $\lambda(s)$ при $s > t$ по (i)–(ii) выражается через $S_\beta(t)$ и события на (t, s): $S_\beta(s) = e^{-\beta(s-t)} S_\beta(t) + \sum_{t<t_j<s} e^{-\beta(s-t_j)}$. Следовательно, вся информация о $\mathcal{F}_t$, влияющая на будущее, содержится в числе $S_\beta(t)$. □

Замечание 3. Для ядра — смеси экспонент $\varphi(\tau) = \sum_{k=1}^{K} \alpha_k \beta_k e^{-\beta_k \tau}$ утверждение переносится дословно: достаточной статистикой служит вектор $(S_{\beta_1}(t), \dots, S_{\beta_K}(t)) \in \mathbb{R}^K$. Для степенных ядер $\varphi(\tau) \propto (c+\tau)^{-p}$ конечномерной достаточной статистики не существует — это принципиальное отличие и причина выбора экспоненциального семейства.

Замечание 4 (вычислительное следствие). По (i)–(ii) значение S_β в любой момент обновляется за $O(1)$ по одному предыдущему значению. Признаки всех «окон» для всей истории пользователя считаются одним проходом по отсортированному логу и хранятся как K чисел на (пользователь, сущность). Это обеспечивает потоковое вычисление на промышленных объёмах, в отличие от оконных агрегатов, требующих пересчёта по скользящему окну.

3.3. Оконные счётчики как предел затухающих

Утверждение 5 (аппроксимация окна)**.** *Пусть $W > 0$, $\varepsilon > 0$, $\delta \in (0, W)$. Существуют $K \in \mathbb{N}$, коэффициенты $c_1, \dots, c_K \in \mathbb{R}$ и показатели $\beta_1, \dots, \beta_K > 0$ такие, что*

$$\sup_{\tau \in [0, W-\delta] \cup [W+\delta, \infty)} \left| \mathbf{1}\left[\tau \le W\right] - \sum_{k=1}^{K} c_k e^{-\beta_k \tau} \right| < \varepsilon.$$

Как следствие, для любой истории

$$\left| C^W(t) - \sum_{k=1}^{K} c_k S_{\beta_k}(t) \right| \;\le\; \varepsilon\, N(t) + \#\{j : |t - t_j - W| < \delta\}.$$

Доказательство. Замена $x = e^{-\tau}$ переводит $[0, \infty)$ в $(0, 1]$, а функции $e^{-k\tau}$, $k = 0, 1, 2, \dots$ — в мономы x^k. Функция $g(x) = \mathbf{1}\left[x \ge e^{-W}\right]$ непрерывна на $[0, e^{-W-\delta}] \cup [e^{-W+\delta}, 1]$; продолжим её линейно на зазор до непрерывной $\tilde{g}$ на $[0, 1]$. По теореме Вейерштрасса существует многочлен p с $\sup_{[0,1]} |\tilde{g} - p| < \varepsilon$. Возвращаясь к τ, получаем первое неравенство с $\beta_k = k$. Второе следует суммированием по событиям: вне δ-окрестности границы окна ошибка на событие не превосходит ε, внутри — не превосходит 1. □

Замечание 6. Утверждение 5 означает, что класс функций истории, представимых деревьями над $\{S_{\beta_k}\}$, по выразительности не беднее класса, представимого деревьями над оконными счётчиками (с точностью до событий, попавших ровно на границу окна). Обратное неверно: гладкое затухание различает «слушал вчера» и «слушал шесть дней назад», тогда как окно $W = 7$ дней их отождествляет. Это — источник возможного прироста качества.

4. Модель повторного потребления

4.1. Интенсивность пары пользователь–объект

Для пары (u, i), уровня связи $r \in R$ и марки $m \in M$ определим подысторию и затухающий счётчик

$$\mathcal{H}_{r,m}(u,i,t) = \{e \in \mathcal{H}(u,t^-) : m_e = m,\ a_r(i_e) = a_r(i)\}, \qquad S_{r,m}(u,i,t) = \sum_{e \in \mathcal{H}_{r,m}(u,i,t)} e^{-\beta_{r,m}(t-t_e)}. \tag{4}$$

Модель: интенсивность взаимодействия пользователя u с объектом i

$$\lambda_{ui}(t) = \underbrace{\mu_{ui}(t)}_{\text{новизна}} + \underbrace{\sum_{r \in R} \sum_{m \in M} \alpha_{r,m}\, \beta_{r,m}\, S_{r,m}(u,i,t)}_{\text{самовозбуждение (повторность)}}. \tag{5}$$

Параметры ядер $\theta = \{(\alpha_{r,m}, \beta_{r,m})\}_{r \in R, m \in M}$ общие для всех пользователей и объектов; при $|R| = 3$, $|M| = 2$ их всего 12. Базовая интенсивность $\mu_{ui}(t)$ отвечает за первый контакт (популярность, контентное сходство) и в данной модели не оценивается: её роль в бустинге играют другие признаки. Хоуксовская часть описывает ровно то, что описывают прямые и косвенные оконные признаки — динамику повторного потребления.

4.2. Интерпретация параметров

- $1/\beta_{r,m}$ — характерное время памяти для связи r и марки m; $\ln 2/\beta_{r,m}$ — период полураспада интереса. Это и есть оценённый из данных ответ на вопрос «какое окно?».
- $\alpha_{r,m}$ — сила возбуждения: ожидаемое число дополнительных событий, порождённых одним событием марки m на уровне r. Если $\hat{\alpha}_{r,m} \approx 0$, связь (r, m) бесполезна — это автоматический отбор типов связей.
- Условие стационарности $\sum_m \alpha_{r,m} < 1$ для каждого r контролируется параметризацией $\alpha_{r,m} = \sigma(\tilde{\alpha}_{r,m})$, $\beta_{r,m} = \text{softplus}(\tilde{\beta}_{r,m})$.

5. Оценивание параметров

5.1. Правдоподобие на одном уровне связи

Чтобы избежать суммирования компенсатора по всему каталогу, параметры оцениваются поуровнево. Фиксируем r. Для пользователя u и значения атрибута $g \in A_r$ рассмотрим поток событий u с объектами, у которых $a_r(i_e) = g$, на обучающем периоде $[0, T]$: моменты $t_1 < \cdots < t_n$ с марками $m_1, \ldots, m_n$. Моделируем процесс *повторных* событий условно на первом контакте t_1:

$$\lambda^{(r)}_{u,g}(t) = \mu_r + \sum_{m \in M} \alpha_{r,m}\beta_{r,m} \sum_{j:\, t_j < t} \mathbf{1}\,[m_j = m]\; e^{-\beta_{r,m}(t-t_j)}, \qquad t \in (t_1, T]. \tag{6}$$

Здесь μ_r — одно число на уровень (фоновая интенсивность возврата после первого контакта); при желании μ_r заменяется на $\mu_r \cdot \nu_u$ с регуляризованной персональной активностью ν_u.

Логарифм правдоподобия потока (u, g):

$$\ell_{u,g}(\theta) = \sum_{j=2}^{n} \log \lambda^{(r)}_{u,g}(t_j^-) \;-\; \mu_r(T - t_1) \;-\; \sum_{m \in M} \alpha_{r,m} \sum_{j=1}^{n} \mathbf{1}\,[m_j = m]\,\big(1 - e^{-\beta_{r,m}(T-t_j)}\big). \tag{7}$$

Последнее слагаемое — компенсатор $\int_{t_1}^{T} (\lambda - \mu_r)\,\mathrm{d}s$ в замкнутой форме, поскольку $\int_{t_j}^{T} \alpha\beta e^{-\beta(s-t_j)}\,\mathrm{d}s = \alpha(1 - e^{-\beta(T-t_j)})$. Полное правдоподобие уровня: $\ell_r(\theta) = \sum_u \sum_g \ell_{u,g}(\theta)$.

Оценка: $\hat{\theta}_r = \arg\max_\theta \ell_r(\theta)$ градиентным методом (Adam) с автоматическим дифференцированием. Все слагаемые (7) выражаются через счётчики (3), которые по Утверждению 2 считаются рекурсивно: для событий марки m

$$S_j = e^{-\beta(t_j - t_{j-1})}\big(S_{j-1} + \mathbf{1}\,[m_{j-1} = m]\big), \qquad S_1 = 0.$$

Численно устойчивая векторизованная форма: $S_j = \exp\big(\text{logcumsumexp}_{k<j}(\beta t_k) - \beta t_j\big)$ внутри сегмента (u, g).

5.2. Организация оценивания

- **Период.** Только обучающий отрезок времени; оценённые $\hat{\theta}$ фиксируются и применяются на валидации и тесте. Это соблюдает point-in-time.
- **Источник событий.** Ядра оцениваются по органическим событиям ($o_e = \text{org}$): события из ленты порождены рекомендателем, и подгонка по ним смешивает поведение пользователя с политикой алгоритма. Альтернатива — ввести o как дополнительную марку, $\alpha_{r,m,o}$, и сравнить оценённые ядра органики и ленты.
- **Единицы времени.** Yambda хранит время в корзинах по 5 с; события в одной корзине имеют $\Delta t = 0$ и не создают проблем для (7), но требуют t_j^- в логарифме — счётчик на момент события не включает само событие.
- **Регуляризация.** Слабый лог-нормальный априор на $\beta_{r,m}$, удерживающий $1/\beta$ в диапазоне от минут до месяцев.
- **Сложность.** $O(|\mathcal{E}_{\text{train}}| \cdot |M|)$ на итерацию; для 10^7 событий — секунды на CPU.

5.3. Диагностика адекватности

Пусть $\Lambda(t) = \int_0^t \lambda(s)\,\mathrm{d}s$. По теореме о перемасштабировании времени (time-rescaling theorem), если модель верна, то величины $\tau_j = \Lambda(t_j) - \Lambda(t_{j-1})$ — независимые $\text{Exp}(1)$. Для экспоненциальных ядер

$$\tau_j = \mu_r(t_j - t_{j-1}) + \sum_m \alpha_{r,m} \sum_{k<j} \mathbf{1}\,[m_k = m]\left(e^{-\beta_{r,m}(t_{j-1} - t_k)} - e^{-\beta_{r,m}(t_j - t_k)}\right)$$

вычисляется в замкнутой форме. Проверка: QQ-график и критерий Колмогорова–Смирнова для $\{\tau_j\}$ против $\text{Exp}(1)$, а также автокорреляция $\{\tau_j\}$. Систематические отклонения укажут на суточную периодичность (лечится множителем $\rho(t \bmod 24\text{ч})$ в μ_r) или на необходимость второй экспоненты в ядре.

6. Признаки для бустинга

Для строки (u, i, t) с оценёнными $\hat{\theta}$ формируется вектор

$$\Phi_{\text{H}}(u,i,t) = \Big(S_{r,m}(u,i,t),\ r \in R,\ m \in M; \tag{8}$$

$$\hat{\lambda}_{ui}^{\text{exc}}(t) = \sum_{r,m} \hat{\alpha}_{r,m}\hat{\beta}_{r,m} S_{r,m}(u,i,t); \tag{9}$$

$$p_h(u,i,t) = 1 - \exp\Big(-\hat{\mu}_r h - \sum_{r,m} \hat{\alpha}_{r,m} S_{r,m}(u,i,t)\big(1 - e^{-\hat{\beta}_{r,m}h}\big)\Big),\ h \in \{1\text{ч}, 1\text{д}, 7\text{д}\}\ \Big). \tag{10}$$

Признак (10) — вероятность хотя бы одного повторного события на горизонте h при условии отсутствия новых событий; он получен интегрированием интенсивности и является калиброванной, интерпретируемой величиной. При $|R| = 3$, $|M| = 2$ вектор Φ_{H} имеет размерность $6 + 1 + 3 = 10$ против нескольких десятков оконных счётчиков, которые он замещает.

7. Экспериментальный протокол

7.1. Данные и разбиение

Yambda-50M; случайная подвыборка $|U| \in \{1000, 2000, 5000, 10000\}$ пользователей с полной историей. Глобальное разбиение по времени с зазорами:

$$[0, T_{\text{tr}}) \xrightarrow{\text{gap}} [T_{\text{va}}, T'_{\text{va}}) \xrightarrow{\text{gap}} [T_{\text{te}}, T'_{\text{te}}),$$

валидация и тест — по 1–2 недели. Строки, метки, кандидаты и порядок событий фиксируются один раз и используются всеми моделями.

7.2. Сравниваемые модели

Все модели — один и тот же градиентный бустинг (LightGBM/CatBoost) с одинаковыми гиперпараметрами, подобранными на валидации для базовой модели; различаются только наборами признаков. Общий блок Φ_0: признаки пользователя, объекта, артиста, контекста (время суток, день недели), популярность (по train), контентное сходство с профилем.

Модель	Признаки	Что проверяет
M_0	$\Phi_0 \cup \Phi_{\text{win}}$ (ручные окна по сетке)	базовый подход
M_1	$\Phi_0 \cup \Phi_{\text{H}}(\hat{\theta}_{\text{MLE}})$	замена окон оценёнными счётчиками
M'_1	$\Phi_0 \cup \Phi_{\text{H}}(\beta$ по лог-сетке, $\alpha \equiv 1)$	нужна ли оценка, или достаточно многомасштабности
M_2	$\Phi_0 \cup \Phi_{\text{win}} \cup \Phi_{\text{H}}$	дополняют ли счётчики окна
M_3	$\Phi_0 \cup \{\hat{\lambda}^{\text{exc}}_{ui}\}$	один хоуксовский признак

7.3. Гипотезы

Гипотеза 1. M_1 не уступает M_0 в пределах доверительного интервала при меньшем числе признаков и без ручного выбора окон.

Гипотеза 2. M_2 превосходит M_0 на малую, но статистически значимую величину за счёт гладкого затухания.

Гипотеза 3. Оценённые $1/\hat{\beta}_{r,m}$ упорядочены согласованно с окнами, которые отбирает жадный forward selection на Φ_{win}: память по треку короче памяти по артисту; память по лайку длиннее памяти по прослушиванию.

Гипотеза 4. Разрыв между M_1 и M'_1 мал: основная польза — в многомасштабном затухании, а не в точном значении β. (Отрицательный результат здесь столь же содержателен.)

7.4. Метрики и статистика

LogLoss и ROC-AUC на тесте; NDCG@K и Recall@K внутри сессий рекомендательных прослушиваний одного пользователя. Доверительные интервалы — кластерный bootstrap по пользователям (строки одного пользователя зависимы); сравнение моделей — парный bootstrap разностей. Дополнительно: кривые качества по $|U|$ для оценки обобщаемости выводов на большую выборку; таблица затрат (число признаков, время расчёта признаков, память, возможность онлайн-обновления).

7.5. Контроль утечек

Автоматический тест: признаки строки (u, i, t) вычисляются по полному логу и по логу с удалёнными событиями при $t_e \geq t$; значения должны совпасть. Эмбеддинги, популярность и $\hat{\theta}$ — только по $[0, T_{\text{tr}})$.

8. Расширения и ограничения

Смесь экспонент. Ядро $\varphi_{r,m}(\tau) = \sum_{k=1}^{2} \alpha_{r,m,k}\beta_{r,m,k}e^{-\beta_{r,m,k}\tau}$ (быстрая и медленная память) сохраняет марковость с вдвое большим состоянием. Сравнение с $K = 1$ по правдоподобию на валидации и по качеству бустинга покажет, нужна ли вторая шкала.

Иерархические параметры. Персональные β_u со сжатием к общему β (эмпирический Байес) — проверка, различаются ли пользователи скоростью забывания.

Сглаживание отношений. Для конверсий вида $C_{r,\text{like}}/C_{r,\text{listen}}$ при малых знаменателях использовать апостериорное среднее Beta–Binomial с априором, оценённым по уровню выше в иерархии (трек ← альбом ← артист ← глобально).

Обучаемое ядро. Нейросетевой агрегатор истории с весами внимания $w(\Delta t, r, m)$ обучается на той же задаче; выученная зависимость $w(\Delta t)$ сопоставляется с $\hat{\varphi}_{r,m}$. Совпадение формы — свидетельство, что нейросеть переоткрывает точечный процесс; расхождение указывает на эффекты, которых нет в экспоненциальном семействе.

Ограничения.

- Модель описывает повторность, а не первый контакт: для пар без истории на всех уровнях r хоуксовские признаки тождественно нулевы, и качество определяется блоком Φ_0.
- События из ленты порождены рекомендателем; модель оценивает не «чистое» поведение, а его смесь с политикой. Оценивание по органике смягчает, но не устраняет проблему.
- Нестационарность (суточные и недельные циклы, тренды) нарушает предпосылки; диагностика через time-rescaling обязательна.
- При большом $|R| \times |M|$ параметры ядер могут терять идентифицируемость (близкие β «сливаются»); лечится регуляризацией и ограничением числа марок.

9. Что именно автоматизировано

Сопоставление с вопросами из постановки задания:

Решение человека	Чем заменено
Окно W	Скорость затухания $\beta_{r,m}$, оценённая по максимуму правдоподобия
Тип связи r	Автоматическое перечисление a_r из схемы данных; отбор через $\hat{\alpha}_{r,m} \to 0$
Способ агрегации	Затухающая сумма как единый примитив; счётчик, время с последнего события и вероятность повтора — её функции
Сочетания признаков	Делегированы бустингу над малым вектором Φ_{H}

Единственное оставшееся человеческое решение — выбор экспоненциального семейства ядер, и оно обосновано не вкусом, а Утверждением 2: только оно даёт конечномерную достаточную статистику и, как следствие, потоковую вычислимость.

Литература для чтения

1. P. J. Laub, T. Taimre, P. K. Pollett. *Hawkes Processes*. arXiv:1507.02822, 2015. — Определения, правдоподобие, рекурсия, симуляция, диагностика.
2. M.-A. Rizoiu, Y. Lee, S. Mishra, L. Xie. *A Tutorial on Hawkes Processes for Events in Social Media*. 2017. — Интуиция и примеры.
3. N. Du, Y. Wang, N. He, L. Song. *Time-Sensitive Recommendation from Recurrent User Activities*. NeurIPS 2015. — Самовозбуждающиеся процессы для повторного потребления.
4. E. N. Brown et al. *The time-rescaling theorem and its application to neural spike train data analysis*. Neural Computation, 2002. — Диагностика адекватности.
5. A. G. Hawkes. *Spectra of some self-exciting and mutually exciting point processes*. Biometrika, 1971; T. Ozaki. *Maximum likelihood estimation of Hawkes' self-exciting point processes*. Ann. Inst. Statist. Math., 1979.